

Raport R1 — Datasets, EDA, Feature Engineering

beDetector • Team beAuth • Honeywell Kościuszkon 2026

Streszczenie

Trzy datasets, łącznie **~186k samples**. TEXTBAT (UT Austin) — gold standard akademicki dla L1 receiver-side, w produkcji. Aissou — published UAV dataset z baseline 99.93%, w produkcji. OpenSky live — real-time ADS-B nad Europą, **wyeksplorowany ale odrzucony z produkcyjnego ensemble** (zachowany dla transparentności — szczegóły w R2 + sekcji *Iteration log* w README).

4 rodziny features (multi-correlator SQM, wideband AGC power, NavSol residuals, trajektorie kinematyczne) z 1 customowym (**secondary_peak_ratio**) i kluczową preprocessingiem (z-score baseline $t < 100s$ per scenariusz).

Pokrywa kryteria: 1 (Problem Understanding), 2 (Dataset Selection & Validation), 3 (Feature Engineering).

Datasety — wielkość i charakterystyka


Three datasets, three sensor modalities, ~186k samples

Dataset	Samples	Features	Sensor type	Labels source
TEXBAT (UT Austin academic)	1,836	24	receiver IF observables	real spoofing recording, per-epoch labels
Aissou (Mendeley UAV)	158,177	80	8-channel GPS receiver	labeled mission CSV (3 spoof types)
OpenSky (live ADS-B)	25,995	17	aircraft state vectors	unsupervised + synthetic injection

TEXBAT 1,836 epok / Aissou 158k wierszy / OpenSky 37k+ rosnąco

TEXBAT i Aissou to opublikowane datasety z literatury. OpenSky — collector zbierał 24/7 z OpenSky Network REST API. Łącznie ~196k samples na 3 domeny.


Class distribution



Rozkład klas per dataset (clean vs anomalous)

TEXBAT skewed do spoof (64%) bo ds7 jest atak-heavy. Aissou zbalansowany 50/50 dla binary task. OpenSky — 100% real clean ADS-B; spoofing labels generated through synthetic injection (real spoof ADS-B traces unavailable globally).


TEXBAT — clean vs ds7 (separowalne wizualnie)



Aggregate features: cleanStatic vs ds7 — wyraźnie różne dystrybucje

Pre-EDA sanity: feature distributions w cleanStatic vs ds7 są separowalne wizualnie. Particularly: `power_*MHz_zscore` skacze przy injection, `sqm_secondary_peak_ratio` łapie code-drift, `clock_error_drift` eksploduje w fazie walk.


TEXBAT ds7 — fazy ataku w czasie



C/N0 over time z zaznaczonymi 4 fazami: injection / stealth / drift / walk

Stealth phase (130–150s) — 20 sekund w którym C/N0 i pseudorange wyglądają identycznie jak clean — tylko carrier phase rotated o π . UT GRID receiver flagged 0/32k epok (0.00%) w stealth. To jest "killer test" dla L1 modelu.


TEXBAT — feature histograms



Distributions kluczowych features

Multi-correlator SQM features z autocorrelation function (41 I + 41 Q taps). Klasyka literatury (Wesson 2018, Phelts, Akos). Dodaliśmy custom **secondary_peak_ratio** — max envelope poza ± 5 tapów od peak'u, rozróżnia stealth od drift.


TEXBAT — z-score per-scenariusz baseline normalization



Per-scenariusz z-score na baseline $t < 100s$ (clean phase)

Nasz custom design: bez tej normalizacji F1 spada z 0.984 do 0.17. Adresuje hardware drift między recording sessions — surowe values powerów różnią się między scenariuszami nawet w fazie clean.

TEXBAT — IQ taps envelope



41 I + 41 Q correlator taps wokół peak'u Promptu

Pełen scan funkcji autokorelacji. Stealth attack rotuje carrier phase π — komponenty I/Q flipują, ale peak amplitude pozostaje bez zmian. SQM features mierzą asymetrię/kształt envelope, nie samą amplitudę — i to pozwala wykryć stealth.


TEXBAT — wideband AGC power across 2/4/8 MHz



Wideband Automatic Gain Control reaguje sub-dB na obecność spoof transmittera

Spoofers wstrzykuje dodatkowy sygnał — AGC w receiverze zmniejsza gain żeby skompensować, dokumentowane jako sub-dB anomalie w paśmie 2/4/8 MHz. Najsilniejsze w paśmie 2 MHz (gdzie sygnał GPS L1 dominuje).

TEXBAT — clock error drift (NavSol)




clean injectionstealth code drift walk

Clock error drift — feature dla fazy walk

Walk phase (400–468s): clock offset rośnie do $\sim 1.27 \mu$ s, position offset ~ 382 m. Ten sygnał jest trywialny do wykrycia (każdy receiver to widzi), ale stealth phase już nie. Multi-feature ML łapie wszystkie 4 fazy.


OpenSky — EDA na collected ADS-B



Snapshots z OpenSky API — coverage Europy

Collector zbierał 24/7. Final dataset: 75k rows, 2341 unikatowych aircraft, 74 snapshotów co ~2 min. Coverage: lat 35–66, lon –10 do +40. Used dla L3 trajectory model evaluation + live demo replay engine.


SHAP — global feature importance L1 (TEXBAT)



Top features na ds7 OOD wg mean|SHAP value|

power_2MHz_zscore dominuje — wideband power anomaly to najsilniejszy sygnał. Drugie miejsce **sqm_asymmetry**, trzecie **secondary_peak_ratio** (nasz custom feature). Walidacja że feature engineering wybrał właściwe sygnały.

SHAP — global feature importance L2 (Aissou)



Top features per-channel Doppler dla L2

Carrier_Doppler na konkretnych kanałach (ch3, ch5) dominuje — model rozpoznaje channel-level spoofing po unormalnej Doppler shift. Spójne z mechanizmem ataku w datasecie Aissou (per-channel injection).