

# Raport R3 — Walidacja, Honest Analysis, Limitacje

beDetector • Team beAuth • Honeywell Kościuszkon 2026


## Streszczenie

Faza 9-11: zidentyfikowaliśmy i **zaadresowaliśmy 3 słabości produkcyjne**. (1) L3v2 v2 miało za-  
wyżone  $F1=0.74$  — faktyczny  $FPR=51\%$  na clean. Po retreningu na  $2\times$  datasecie: uczciwa kalibracja  
 $FPR=10\%$ ,  $F1=0.398$ . (2) Drift attack  $<1\text{ km/min}$  poniżej GPS noise floor — niewykrywalny z samej  
pozycji+prędkości. (3) Continuous monitoring po 5 h pokazał plateau metryki — problem architekту-  
ral, nie data-bound.

Demo: real ADS-B replay z 2026-05-09 — **4/5 aircraft alarm w pierwszej klatce** po starcie spo-  
ofingu (latencja  $\sim 1$  snapshot).

*Pokrywa kryteria: 6 (Evaluation), 8 (Interpretation), 9 (Reproducibility).*


## Threshold sweep — L1 (TEXBAT)



### F1 / Precision / Recall / FPR vs threshold dla XGBoost L1

Operacyjny threshold 0.05 zapewnia  $\sim F1=0.984$  z Precision=1.000. Optimal F1=0.985 przy threshold=0.0074 — czyli model jest dobrze separowany w niskich thresholdach. Aviation safety: niski próg = preferujemy recall nad FPR.


## L1 — threshold tuning per phase



### Wpływ thresholdu na recall każdej fazy ds7

Stealth phase: 100% recall stabilny dla  $\text{thr} \leq 0.7$ . Injection: bardziej wrażliwy — recall spada poniżej 0.5 przy  $\text{thr} = 0.5$ . Decyzja: operating threshold 0.05 maksymalizuje recall stealth + injection.


## Calibration — L1 + L2 reliability diagram



Czy  $\text{score}=X$  faktycznie znaczy  $P(\text{spoof})=X$ ? Reliability curve

L1 dobrze skalibrowany w predykcjach  $>0.5$ . L2 multi-class: model jest **overconfident** — predykcja 1.0 nie zawsze = 100% pewności. Adresowane przez per-scenario p99 calibration na clean baseline (`l2_threshold_calibrated`).


## L3v2 v3 honest threshold sweep (Faza 11)



**Przy FPR=10%: precision=0.79, recall=0.25 (operational). Przy FPR=75%: F1=0.78**

**Krytyczne odkrycie Faza 11:** v2 IsoForest miał zawyżone F1=0.74 bo testowane na własnym training distribution z FPR=51%. v3 trenowany na 2× datasecie ujawnił uczciwą jakość. Operating point chosen for aviation: FPR=10%, operational F1=0.398.

## Real Flight 8243-style replay




### Reconstruction Flight 8243 spoofing scenario na live OpenSky data

Test detekcji 30km drift attack na real ADS-B. L3v2 score 0.51 > threshold 0.5. 100km teleport — score 0.71 (CRITICAL). Walidacja że L3 multi-time wykrywa real-world Flight 8243-style drift.

## Real flight replay z 2026-05-09 — 5 longest tracks


Real ADS-B replay — 5 longest tracks from 2026-05-09, drift attack injected at track midpoint



**Drift attack na 5 prawdziwych torów lotniczych nad Europą — alert per-snapshot**

4/5 aircraft alarm w pierwszej klatce po starcie spoofingu (latencja=0). 1 aircraft (01022b) latencja 5 snapshotów (~10 min). Real-time demo na świeżych ADS-B z dzisiejszego ranka.

## Drift detector — kinematic residual filter




### Lekka heurystyka: position prediction vs reported velocity

Frozen / teleport / implausible\_velocity: 99-100% recall przy 5km threshold. **Subtle drift (<1km/min)** = **niewykrywalny** — poniżej naturalnego GPS noise floor + ADS-B reporting jitter. Honest limitation, dokumentowane w roadmapie.




## Continuous validation — quality vs data growth



Co 30 min retraining L3v2 na rosnącym datasetcie. 4× wzrost danych przez 5h.

Plateau jest architectural, nie data-bound. ROC-AUC flat  $\sim 0.70$  niezależnie od wielkości datasetu. Per-attack recall stabilny. Wniosek: więcej ADS-B nie pomoże; potrzebujemy innych sensorów (INS fusion, multi-receiver TDOA).


## Cross-domain unified score (score\_unified())



**6-krokowa eskalacja ataku: subtle drift → carrier distortion → full spoof**

API `ml/inference.py:score_unified()` łączy L1 (signal) + L2 (UAV) + L3v2 (trajectory) w jeden per-incident score. Alert level mapping:  $\geq 0.7$  critical,  $\geq 0.4$  warn, else ok. Spójne z FE thresholdami.


## TEXBAT — SHAP beeswarm (feature impact distribution)



### SHAP beeswarm — distribution feature impact w teście ds7

Każdy punkt = jedna predykcja, kolor = wartość feature, x = SHAP impact. `power_2MHz_zscore` ma największy spread (silnie wpływa na predykcję). Walidacja kierunku features (high power → spoof).


## Aissou — SHAP beeswarm (per-channel features)



### Distribution SHAP impact na Aissou binary


Carrier\_Doppler ch3 i ch5 dominują — model rozpoznaje channel-level spoofing po unormalnej Doppler shift. Spójne z mechanizmem ataku w datasetcie Aissou.

# Live demo — Onboard, baseline OK (zielony verdict)



**Dashboard w trybie Onboard, scenariusz normal\_waw\_gdn**  
Layer L1 (TEXBAT) ratio 0.70×, Layer L2 (Aissou) 0.96× — oba poniżej thresholdu, verdict **OK** (zielony). Top reasons: anomalie kanału PRN4/PRN6 (informacyjne, sub-threshold). Footer: 5 modeli z F1 score per warstwa.


## Live demo — Onboard, ostrzeżenie WARNING (pomarańczowy)



**Atak kanałowy Aissou: timeline strip pokazuje pomarańczowy tick, alert feed: “#017 0.34× L2 WARNING”**


Pasek “LAST 30” pokazuje pojedynczy pomarańczowy tick gdy ratio L2 przekroczyło próg 1.0×. Alert feed po prawej zarejestrował zdarzenie. Verdict wraca do OK, ale tranzycja kolorów jest widoczna na timeline.

## Live demo — Live Globe, atak teleport (czerwony ALERT)



baltic\_teleport — banner “SPOOFING DETECTED — IFOREST\_V2 — RYR2K6 ratio 1.60x”  
Czerwony banner u góry, czerwony pulsujący marker nad Bałtykiem, czerwony alert sidebar (“Ensemble model: CRITICAL”). Ensemble bar 1.60x (czerwony), Anomaly score 0.85x (zielony) — pokazuje że trajectory layer (L3 multi-time) wykrywa skok pozycji ~280 km, mimo że supervised layers go nie widzą.

## Live demo — Explain modal (real SHAP TreeExplainer)



### Per-tick snapshot z prawdziwymi wartościami SHAP dla L1

Modal po kliknięciu “Explain” pobiera SHAP values z backendu `/api/explain/{tick_id}`. Top features: `power_2MHz` contribution  $-3.129$ , `clock_error_m`  $-0.973$ , `error_flag_any`  $+0.690$  (czerwony pasek = positive contribution, dla danego tick *nie* skłania do alertu bo overall ratio  $0.14\times$ ). Base log-odds, predicted proba i ratio widoczne na dole — pełen pipeline interpretowalności end-to-end.



## Iteration log — co odrzuciliśmy i dlaczego

**OpenSky / IsoForest (L3v1 + L3v2)** — wytrenowane, evaluowane, odrzucone z produkcyjnego ensemble.

- **Different threat surface:** TEXTBAT/Aissou wykrywają spoofing na poziomie sygnału (signal layer) i kanału (channel layer) na samym samolocie; OpenSky widzi tylko już-zspoofowane pozycje broadcastowane przez ADS-B. Dodanie L3 do ensemble blurowało, co verdict właściwie znaczy.
- **Niższe F1, wyższy false-positive rate:** L3v1 = 0.789, L3v2 = 0.743 vs L1 = 0.984, L2 = 0.976 — OR-fusion zniżyłby precision bez pomocy headline scenariuszom.
- **Brak czystych labels:** trenowane unsupervised + synthetic injection; brak real-world ground truth do validacji.

**LSTM-AE trajectories (L4)** — autoencoder trajektorii trenowany na V100 nie pobił prostszego L3v2 multi-time IsoForest na żadnej intensywności ataku (Faza 10). Wycięty z ensemble przed demo, training curve i score distribution zachowane w `presentation/img/lstm_*.png`.

**Co weszło do produkcji:** L1 TEXTBAT XGBoost (24 features, F1=0.984), L2 Aissou XGBoost (80 features, F1=0.976), Ensemble OR z `max(score / threshold)`, sub-millisecond inference, SHAP TreeExplainer dostępny przez Explain modal.